


Qu'est-ce qui rend une ville saine ?

Une analyse des villes européennes par machine learning

Rahel Park


26.06.2026

Introduction



Données et méthodologie

Harmonisation across geographic levels



Final variable set

Socioeconomic

GDP, employment, tertiary education, doctors per 100k, unmet medical need

Behavioural

obesity, smoking

Environmental

PM2.5, NO2, green space, night noise exposure

Demographic & urban


old-age dependency, cars per 1000, road deaths, population

L'obésité et le PIB dominant le modèle (SHAP, Random Forest)


RF model :

R^2 train: 0.889

R^2 test: 0.692



Au niveau pays, PIB, obésité et mortalité s'alignent




Une fois les facteurs nationaux retirés : que reste-t-il à la ville ?

Random Forest hors obésité, tabac et besoins médicaux — valeurs SHAP

RF model :

R^2 train: 0.790

R^2 test: 0.498




Valeurs réelles vs prédites : modèle complet (Random Forest, R2 0.69)

Most under-predicted (model thinks healthier than reality):

	city	Country	actual	predicted	residual
	Łódź	PL	427.447957	286.617712	140.830246
	Vilnius	LT	307.523051	184.515502	123.007549
Bratislava (greater city)		SK	258.672044	139.247497	119.424547
	Klaipėda	LT	400.592956	287.137180	113.455776
Budapest (greater city)		HU	272.322105	184.764126	87.557979
	Wrocław	PL	424.295318	341.809534	82.485784
	Legnica	PL	366.558832	284.104978	82.453853
	Žilina	SK	279.844733	210.873546	68.971188
	Panevėžys	LT	387.604010	319.957900	67.646111
	Schwerin	DE	281.978471	220.083501	61.894970


Most over-predicted (model thinks sicker than reality):

	city	Country	actual	predicted	residual
	Rzeszów	PL	202.281867	314.176317	-111.894450
Creil (greater city)		FR	169.829112	269.628371	-99.799260
	Oulu/Uleåborg	FI	146.735169	242.730462	-95.995292
	Opole	PL	246.406579	333.455326	-87.048746
	Veszprém	HU	264.380162	340.713324	-76.333162
	Nowy Sącz	PL	238.151267	309.315933	-71.164666
	Przemysł	PL	287.930253	356.354752	-68.424499
	Zlín	CZ	207.505054	267.199715	-59.694661
	Weimar	DE	204.523700	257.858744	-53.335044
	Bielefeld	DE	200.601546	246.349186	-45.747640




Où le modèle se trompe révèle autant que là où il réussit

Mortality: low (blue) to high (red); bubble size = GDP PPS



Where the model misses – red = under-predicted, blue = over-predicted



Recommandations

Au niveau national — les associations les plus fortes

- L'obésité et le tabac sont les variables les plus fortement associées à la mortalité prématurée dans le modèle. Les politiques de santé publique nationales — prévention de l'obésité, lutte antitabac — apparaissent donc comme les pistes les plus prometteuses. L'accès aux soins (besoins non satisfaits, densité de médecins) est associé à la mortalité indépendamment du PIB.

Au niveau de la ville — ce qui reste corrélé une fois le contexte national neutralisé

- Une fois les facteurs nationaux retirés, les variables urbaines les plus liées à une faible mortalité sont d'abord structurelles : développement économique et éducation supérieure. Le capital humain ressort comme la piste municipale la plus forte.
- Les variables environnementales — qualité de l'air, espaces verts, bruit nocturne, dépendance automobile — montrent des associations protectrices constantes mais d'ampleur plus modeste.
- *Le message honnête* : il n'existe pas de raccourci urbain évident. Les facteurs les plus liés à la santé d'une ville — richesse, éducation, comportements de santé — relèvent surtout du long terme et de l'échelle nationale. L'aménagement urbain est associé à des gains réels mais marginaux.
- Ces résultats étant corrélacionnels, ils désignent des pistes à prioriser, non des effets causaux démontrés.

Limites et perspectives

- Étude écologique et transversale : les associations ne sont pas causales. Variables manquantes importantes — consommation d'alcool, qualité de l'alimentation, exposition industrielle historique, inégalités intra-urbaines.
- L'échec systématique du modèle sur les villes post-industrielles de l'Est suggère que des facteurs structurels comptent énormément mais échappent aux données disponibles.
- Perspectives : intégrer la consommation d'alcool et de meilleurs indicateurs de mode de vie ; descendre à l'échelle du quartier, là où se concentrent les inégalités intra-urbaines.
- Passer à une approche longitudinale : suivre chaque ville dans le temps et comparer celles dont la mortalité s'améliore à celles qui stagnent. La période 2022–2024 offrirait un premier point de comparaison une fois les données Eurostat complètes (publication actuellement décalée).